

基于特征结合与权重对抗训练的鲁棒模型水印方案

高光勇^{1,2)}, 徐梓棋^{1,2)}, 方巍^{1,2)*}

¹⁾ (南京信息工程大学数字取证教育部工程研究中心 南京 210044)

²⁾ (南京信息工程大学计算机学院、网络空间安全学院 南京 210044)
(002141@nuist.edu.cn)

摘要: 模型水印方案是用于保护深度神经网络模型所有者对其所有权的信息隐藏技术。针对现有模型水印方案无法有效抵抗水印去除攻击的问题, 提出一种基于特征结合和权重对抗训练的模型水印方案。该方案从特征结合角度融合原始训练数据集图像以构造触发集; 在水印嵌入阶段, 对模型进行权重对抗训练, 将扰动注入模型权重以模拟水印攻击环境, 从而有效提高水印鲁棒性。在 CIFAR-10 数据集上的实验结果表明, 与传统黑盒后门水印方案相比, 所提方案在面对微调、覆写攻击时水印提取率可以达到 100%。同时针对各类水印去除攻击, 该方案水印提取率都可以保持在 80% 以上。

关键词: 模型水印; 深度神经网络; 所有权验证

中图分类号: TP391.41 DOI: 10.3724/SP.J.1089.202*.00805

Robust Model Watermarking Scheme Based on Feature Combination and Weight Adversarial Training

Gao Guangyong^{1,2)}, Xu Ziqi^{1,2)}, and Fang Wei^{1,2)*}

¹⁾ (Engineering Research Center of Digital Forensics, Ministry of Education, Nanjing University of Information Science & Technology, Nanjing 210044)

²⁾ (School of Computer Science, Cyberspace Security, Nanjing University of Information Science and Technology, Nanjing 210044)

Abstract: Model watermarking scheme is the information hiding technique for the owners of deep neural network model to protect model ownership. To address the issue of existing model watermarking schemes being ineffective against watermark removal attacks, a model watermarking scheme based on feature combination and weight adversarial training is proposed. This scheme fuses the original training dataset images from a feature combination perspective to construct the trigger set. During watermark embedding, weight adversarial training is applied to the model, injecting perturbations into the model weights to simulate the watermark attack environment, thereby effectively enhancing watermark robustness. Experimental results on CIFAR-10 dataset demonstrate that compared to traditional black-box backdoor watermark schemes, the proposed scheme achieves a watermark extraction rate of 100% when facing fine-tuning and overwriting attacks. Meanwhile, for various watermark removal attacks, the extraction rate of this scheme can be maintained at above 80%.

Key words: model watermarking; deep neural network; ownership verification

收稿日期: 2023-12-18; 修回日期: 2024-05-27. 基金项目: 国家自然科学基金(42075007); 苏州大学江苏省计算机信息处理技术重点实验室项目(KJS2275); 南京北极阁气象科技创新研究院开放课题(BJG202306). 高光勇(1973—), 男, 博士, 教授, 博士生导师, CCF 高级会员, 主要研究方向为信息隐藏、人工智能安全; 徐梓棋(1999—), 男, 硕士研究生, 主要研究方向为人工智能安全; 方巍(1975—), 男, 博士, 教授, 博士生导师, CCF 高级会员, 论文通信作者, 主要研究方向为气象信息处理、计算机视觉。

近年来,随着深度学习技术的进步,构建深度神经网络(deep neural network, DNN)模型的成本逐渐高昂,训练高性能大模型往往需要投入庞大的数据集和计算资源。例如,由 OpenAI 公司开发的 ChatGPT 大模型^[1]训练一次的成本在 200 万~1 200 万美元之间,同时 ChatGPT 大模型在发布后得到了商业化应用,用户需为查询模型服务支付费用,此时 DNN 模型的构建成本和商业价值使其成为潜在攻击者的窃取目标。因此,为了维护模型所有者权益,验证 DNN 模型的所有权成为亟需解决的议题。

现存数字水印技术的保护对象几乎都是多媒体内容^[2-4],无法直接将相关方法应用于 DNN 模型的所有权保护任务中。受到传统数字水印的启发,研究人员提出 DNN 模型水印。模型水印是通过将水印信息(即可验证信息)在不损害 DNN 模型使用价值的前提下嵌入到模型中的安全技术^[5],按照所有者在水印提取阶段可获取信息的差异,分为白盒水印和黑盒水印。

白盒水印方案直接将水印信息注入模型参数或结构中^[6]。在提取阶段,模型所有者从 DNN 模型权重中提取已嵌入信息来验证其所有权。但是在实际应用中,由于盗版 DNN 模型服务通常是远程部署的,因此获取模型内部信息的前提无法实现;黑盒水印方案则是利用触发集构造输入/输出对,在提取阶段只需验证 DNN 模型的输出结果是否符合预期的标签,其中,基于后门^[7]和基于对抗样本^[8]的触发集设计是黑盒水印的常用设计思路。前者通过后门将预先设计的触发集嵌入模型;后者选取对抗样本作为触发器,通过对水印模型进行对抗训练,使其能对所选对抗样本输出正确标签值以验证所有权。

现有黑盒水印的触发集图像一般是自主设计的抽象图像或者训练集之外的图像,其与原始训练集分布不一致,增加了水印嵌入时模型的学习成本。本文从特征结合角度出发,在不引入新特征的前提下,仅利用原始训练集中图像特征构造触发集。此时,由于触发集和原始训练集分布一致,可以减少模型记忆水印信息的难度和水印嵌入对原始任务精度的损害。同时,大多数黑盒方案易受水印去除攻击的威胁。水印去除攻击可修改模型的权重参数使模型遗忘水印信息,在权重改变后,使用对抗样本水印方案的模型的决策边界也会产生变化,水印提取率将大幅降低。

为了改进触发集设计与抵御上述攻击,本文提出一种新颖的基于特征结合与权重对抗训练的

鲁棒模型后门水印方案。首先通过特征结合,利用原始训练集构造出水印触发集;然后在水印的嵌入训练中对模型权重加以扰动,充分进行权重对抗训练以增强水印鲁棒性。

本文方案的关键是在嵌入水印信息的阶段,通过添加权重扰动进行权重对抗训练,在模型中模拟水印去除攻击的环境,实现增强模型水印的鲁棒性;同时,从特征结合角度出发,设计了特征混合与特征迁移触发集 2 类新型可降低模型水印学习成本的触发集。其中,采用特征混合触发集的水印造成的模型原始任务性能下降更小,并且鲁棒性强;特征迁移触发集则与正常图像在视觉上一致,具有规避可疑图像检测的效果。

1 相关工作

1.1 白盒水印

白盒水印通过修改待保护模型的权值或结构以嵌入水印,进行所有权验证时,所有者需要访问可疑模型的内部信息(参数或结构)来提取水印。

2017 年, Uchida 等^[6]提出第 1 个模型水印方案,通过投影矩阵将水印嵌入模型权重中,使用密钥矩阵与权重运算完成水印提取,但该方案容易被检测和去除,鲁棒性较差^[9]; Chen 等^[10]从溯源的角度出发提出 DeepMarks,针对不同的模型为使用者分配唯一的二进制代码,将其作为指纹嵌入模型权重,能有效地验证所有权并追踪盗版模型; Liu 等^[11]优化权重选取方案,并用挑选的权重构造残差值作为水印的载体,使水印的嵌入位置更加隐蔽。与直接嵌入权重的方案不同, Rouhani 等^[12]提出的 DeepSigns 方案将一组字符串作为水印,嵌入到 DNN 模型的激活层的概率密度函数中,分发记录了水印位置信息的密钥给模型使用者,需要使用该密钥才可得到激活层概率分布中的水印,在可溯源的基础上增强了抵御覆写攻击的鲁棒性; Wang 等^[13]提出通过独立的水印嵌入与提取模型完成水印过程,选取目标模型已收敛的权重,最后通过反向传播更新权重完成嵌入。

与上述将水印嵌入模型参数的方案不同, Fan 等^[14-15]提出修改模型结构的方案,在模型的卷积层之后额外添加护照层以当作水印,使得模型性能在护照存在时保持不变,一旦攻击者尝试修改或者伪造护照,模型的原始分类精度便会急剧下降,因此能够抵御伪造攻击;但是这种方案对原始性能的影响较大。针对该缺陷, Zhang 等^[16]提出改

进方案, 通过在护照层中引入可识别护照的额外分支, 当需要验证模型版权的归属时才提供给模型使用者护照和护照感知分支; Lou 等^[17]同样以模型结构为水印, 使用神经网络结构搜索来确定可嵌入水印的结构位置, 在搜索空间中找到最佳模型结构, 并在原始数据集上训练以获取水印模型。

1.2 黑盒水印

黑盒水印设定一组输入/输出对构成触发集, 通过训练模型学习触发集的映射关系完成水印嵌入, 该类方案更具实用性。

Zhang 等^[7]给出 3 种黑盒触发集设计方法, 分别为挑选在原始训练集之外的图像、对图像注入噪声以及在图像上添加字符串, 并进行后门植入和后门映射^[18]完成水印的嵌入与提取; Adi 等^[19]则使用自行设计的一组抽象图像构造触发集; Jia 等^[20]针对水印移除攻击, 从耦合性角度提出一种纠缠水印方案, 将触发集与模型的原始训练数据纠缠在一起以强化耦合性, 如果移除水印则模型原始分类精度也会随之降低; Li 等^[21]和 Xue 等^[22]从频域角度触发, 对图像的频域嵌入数字水印来构造触发集, 提高了触发集隐蔽性。为了减少水印对原始性能的破坏, Hua 等^[23]通过对水印嵌入添加约束损失函数提高保真度; Le Merrer 等^[8]使用 IFGSM 方法^[24]生成对抗样本当作触发集, 通过微调模型决策边界实现水印嵌入; Chen 等^[25]提出的 BlackMarks 方案同样使用对抗样本, 通过对抗训练将所有信息以二进制形式嵌入到输出结果, 提高水印容量; Yang 等^[26]将黑盒模型水印训练过程转化为双层优化问题, 旨在找出与模型紧密关联的验证样本, 并用最小的扰动构造对抗样本, 与普通的对抗样本方案相比, 该方案在保真度和鲁棒性上均有所提升。

除了通过后门和对抗样本的方式, 许多工作从新的角度提出水印方案。Chen 等^[27]提出一种测试框架, 通过多种测试计算目标模型和可疑模型之间的相似度, 若相似度高于阈值, 则可疑模型为盗版模型。由于攻击者可能利用代理模型攻击, 即通过间接查询目标模型服务的方式生成一个具有相同功能的代理模型, 因此 Szyller 等^[28]的 DAWN 方案在攻击者访问模型服务时对返回的输出进行修改, 使其变为错误标签, 最终攻击者使用这些错误标签训练出的代理模型将存在隐含的后门, 该方案的本质是通过代理模型注入后门进行版权验证; Charette 等^[29]通过在模型输出中注入特定的信号分布, 使代理模型也能学习到这种分布, 从而

验证所有权。

2 背景知识

2.1 黑盒后门水印

黑盒后门水印的过程可以分为嵌入和提取阶段。在嵌入阶段, 训练模型学习触发集图像与预先设定标签之间的映射关系; 在提取阶段, 将训练后的模型输入触发集, 通过对比模型输出与预先设定标签完成水印提取和验证版权。嵌入方式一般有从头训练嵌入和微调嵌入 2 种。从头训练嵌入是将触发集与原始训练集一同作为训练数据投入初始模型的训练中, 在这种方式下, 模型的训练阶段即水印嵌入阶段; 微调嵌入则是对使用原始训练集完成训练后的模型进行微调, 以嵌入水印。通常, 以从头训练嵌入的水印效果要优于微调嵌入。水印设计的关键内容是触发集模式、训练策略、输出模式, 即设计触发集、设计嵌入方式以及设计验证方式。

2.2 相关概念

下面对黑盒后门水印过程涉及的相关概念进行解释, 分为名词解释和水印去除攻击

2.2.1 名词解释

目标模型。模型所有者的需要添加水印的待保护模型, 尚未经过训练。

水印模型。由目标模型经过水印嵌入而得, 具有水印信息, 能够进行所有权验证。

干净模型。训练数据集中不包含触发集, 不可验证所有权, 容易被攻击者窃取。

可疑模型。具有盗版模型可能性的模型, 一般为模型攻击者提供在远程服务上。

原始任务。本文规定模型具有原始和水印 2 种分类任务。模型的原始训练数据集(如 cifar-10)训练即为原始任务。

2.2.2 水印去除攻击

微调。利用原始训练数据集再训练模型, 更新后的权重将降低水印提取率

迁移学习。利用原始训练数据集之外的新数据集再训练模型, 新数据集与原始数据集分布差距越大, 其对水印的破坏越强。

权重剪枝。模型压缩方法之一, 通过将权重置零来移除权重连接, 使模型遗忘水印信息。

覆写。在水印模型上添加新水印, 以此覆盖原水印, 降低原水印的提取率。

3 本文方案

3.1 框架设计和流程

本文方案由构建触发集、嵌入水印和所有权验证

证 3 个阶段组成, 其框架如图 1 所示.

(1) 构建触发集. 从特征结合角度构造了 2 类水印触发集, 二者的模型保护效果各有优劣.

(2) 嵌入水印. 使用从头训练的方式嵌入模型




图 1 本文方案框架

水印, 将触发集和原始训练集一起投入到目标模型的训练中, 训练完毕则水印完成嵌入. 同时, 在嵌入水印时加入权重扰动, 以提升水印鲁棒性.

(3) 所有权验证. 通过水印提取率来验证所有权. 输入触发集到模型以获取输出结果, 经过比对预先设置的标签值计算水印提取率, 若提取率大于阈值则验证成功.

3.2 触发集设计

本文从特征结合角度设计 2 种触发集: 特征混合触发集与特征迁移触发集, 其分别对应的模型水印简称为特征混合和特征迁移. 由于特征混合触发集在应用中容易被攻击者检测, 因此又设计了特征迁移触发集. 实验表明, 特征混合触发集具有两点优势: 一是与特征迁移触发集相比, 造成原始任务精度下降更小; 二是特征混合在抵御迁移学习和剪枝攻击时更加鲁棒. 所以也将特征混合触发集作为可供选择的水印触发集. 特征混合触发集的流程如下: 首先从原始训练集 T 中挑选一部分图像集合 T_{select} 作为构造水印触发集的原材料; 然后通过特征结合方法将 T_{select} 图像融合出新图像, 利用新图像完成模型水印嵌入; 最后将新图像输入水印模型进行分类置信度测试, 选取置信度较高的图像作为后续所有权验证的触发集. 触

发集图像集合为

$$T_{\text{trigger}} = \{I_1, I_2, \dots, I_k, \dots, I_n\};$$

其中, n 表示图像总数, I_k 表示单幅触发集图像. 模型所有者设定的触发集标签构成集合

$$L_{\text{trigger}} = \{L_1, L_2, \dots, L_k, \dots, L_n\};$$

其中, L_k 表示所对应 I_k 图像的标签值.

3.2.1 特征混合触发集

特征混合方法通过过滤图像 I_f 构造出触发集. I_f 将 2 幅原始训练集图像分解并合并为一幅图像, 首先以 w 和 h 分别表示过滤图像横向和纵向像素值; 然后从高斯分布中随机采样出 wh 个取值在 0~255 的随机值, 将其作为像素构成灰度图像 I_{grey} ; 最后利用公式

$$I_f[i] = \begin{cases} 1, & \text{if } I_{\text{grey}}[i] \in \max(\lambda wh, I_{\text{grey}}) \\ 0, & \text{otherwise} \end{cases} \quad (1)$$

将灰度图像 I_{grey} 变换为二值图像, 该二值图像即是所需的过滤图像 I_f . 其中, $I_f[i]$ 表示过滤图像第 i 个像素, $I_{\text{grey}}[i]$ 同理; λ 表示白色像素占总像素的比例, 本文设置 λ 为 0.5, 即黑白区域各占 I_f 的 50%; λwh 表示过滤图像中白色像素数量; $\max$ 函数返回一个集合, 其元素为灰度图像 I_{grey}

中灰度值最大的前 λwh 个像素. 最终, 式(1)将 $\max$ 函数返回的 λwh 个像素设置为白色像素, 其余像素则设置为黑色像素.

从原始训练集的子集 T_{select} 中随机挑选 2 幅图像 I_u 和 I_v , 通过公式

$$I_k = I_f I_u + (1 - I_f) I_v \quad (2)$$

与式(1)计算出的过滤图像 I_f 进行运算, 生成触发集图像. 其中, I_k 表示构造的触发图像; $I_f I_u$ 将图像 I_u 与图像 I_f 白色像素的重叠区域取出, 填充图像 I_k 的相应区域; $(1 - I_f) I_v$ 则取出图像 I_v 与图像 I_f 黑色像素的重叠区域, 填补触发集图像 I_k 的剩余部分.

特征混合图像实例如图 2 所示. 可以看出, 每个触发集图像 I_k 都拥有 2 个原始图像的部分特征, 但是存在明显的 2 个图像拼接所形成的割裂感, 在验证水印时, 触发集易被攻击者检测为可疑图像.




图 2 特征混合实例

3.2.2 特征迁移触发集

特征迁移方法构造的触发集图像将在视觉效果上与原训练图像保持一致, 以此躲避攻击者的可疑图像检测. 本文方案从图像风格特征的角度出发, 利用 CycleGAN(cycle generative adversarial network)^[30]设计触发集. CycleGAN 是一种生成对抗网络, 可以实现图像的风格特征迁移, 其通过添加循环一致性损失函数, 能够在无成对数据集的条件下对图像的风格特征进行提取. 通过该网络将提取的风格特征迁移至新图像上, 即可构造特征迁移触发集. 该构造过程的公式为

$$G(\cdot) = \text{CycleGAN}(X_c, X_s) \quad (3)$$

$$T_{\text{trigger}} = G(X_{\text{sample}}) \quad (4)$$

其中, X_c 和 X_s 表示从目标模型的原始训练数集

T 中挑选 2 个不同类别的集合, X_{sample} 表示从 X_c 中选出部分图像构成的子集. 首先将 X_c 和 X_s 作为 CycleGAN 的训练数据, 根据式(3)训练 CycleGAN 从 X_c 到 X_s 的单向图像特征迁移功能, 经训练后得到生成器 $G(\cdot)$; 然后将 X_{sample} 输入 $G(\cdot)$ 生成触发集 T_{trigger} . 这样构造的触发集将具有 X_s 的部分特征.

特征迁移图像部分实例如图 3 所示, 其中, X_c 和 X_s 分别取飞机类和猫类图像时的触发集. 可以看出, 使用该方法生成的触发集图像与正常图像在视觉上一致, 可以有效地抵御可疑图像检测.




图 3 特征迁移实例

3.3 权重对抗训练

由于记忆水印信息的权值可能会在水印去除攻击(如微调)的影响下改变, 因此会降低水印提取率, 本文方案在水印嵌入阶段引入权重对抗训练. 将式(2)(4)生成的触发集与原始训练集一起训练模型, 在训练过程中对权重参数添加随机扰动模拟水印去除攻击环境, 进行对抗训练以增强水印的鲁棒性.

(1) 确定权重对抗训练需要添加的扰动大小和方向. 扰动的计算公式为

$$p = \alpha \frac{g}{\|g\|_2} \quad (5)$$

其中, g 表示模型正常训练时用于权重更新的梯度, $g = \frac{\partial L(W, x, y)}{\partial W}$; α 表示扰动因子; L 表示模型损失函数; x 和 y 分别表示输入数据和对应标签. p 的大小可通过超参数 α 设定.

(2) 确定添加扰动的模型权重数量及其位置. 由于注入扰动的权重总数不宜过多或过少, 本文方案采取对模型一半的权重进行添加扰动; 此外, 扰动添加的位置应当随机, 可以尽量还原水印攻击的环境, 因此本文使用二值掩码进行随机添加扰动. 本文方案从伯努利分布中随机采样构造二值掩码 B , 选择出需要添加扰动的模型权重, B 的各元素值由 0 和 1 组成, 0 表示不添加扰动, 1 表示添加扰动, 同时规定 B 中 1 所占比例为 50%. 式(5)的扰动 p 通过公式

$$W_p = W + pB \quad (6)$$

将掩码 B 与扰动 p 相乘后再与模型权重 W 相加, 得到注入扰动后的权重 W_p .

(3) 计算模型的扰动梯度并进行权重更新. 由于式(6)已经完成权重扰动的添加, 将注入扰动的权重 W_p 代入公式

$$g_p = \frac{\partial L(W_p, x, y)}{\partial W_p} \quad (7)$$

求得扰动梯度 g_p . 然后将式(5)计算的 g 与式(7)的 g_p 相加, 利用公式

$$W = W - \beta(g + g_p) \quad (8)$$

进行权重更新以完成训练. 其中, β 表示学习率, 可以修改梯度更新的步长. 与正常的水印嵌入训练相比, 本文方案加入了扰动损失. 每轮训练中, 模型通过扰动损失计算扰动梯度并根据式(8)更新权重, 即模型会将扰动对水印的影响考虑在内, 同时强化水印在添加扰动情况下的提取效果. 因此, 水印鲁棒性将能够在该模拟攻击环境下得到强化.

3.4 所有权验证

本文方案以黑盒方式进行验证. 在黑盒场景下, 一个模型所有者 A 拥有多个深度学习模型 $\{D_1, D_2, D_3, \dots, D_m\}$, 并利用这些模型提供远程服务 $\{S_1, S_2, S_3, \dots, S_m\}$, 存在一个模型攻击者 B , 其目的是窃取 A 的正版模型 D_q (q 取值 $1 \sim m$) 以形成盗版模型 D'_q , 并建立一个新远程服务 S'_q , 以此牟取非法利益. 此时, 所有权验证仅需要模型所有者对 DNN 模型服务输入触发集, 即可完成对模型的水印提取. 但是, 一方面, 可疑模型可能会被攻击者修改, 导致水印无法完美提取; 另一方面, 如果可疑模型实际上是干净模型, 那么就算提取出了部分水印也应该判断为验证失败. 实际应用中, 需要设定一个阈值来进行所有权验证. 本文设定阈值 $V = 50\%$, 若水印提取率超过阈值 V 则所有权验证成功.

在验证阶段, 假设 A 的所有模型都已嵌入本文水印, 所有者对远程服务 S'_q 输入触发集图像, 水印提取率 E_w 的计算公式为

$$E_w = \frac{\sum_{k=1}^n \text{Judge}(D(I_k) = L_k)}{n} \quad (9)$$

其中, n 表示触发集图像个数; Judge 函数用于判断模型输出是否与设定标签相符, 若相符返回 1, 反之则返回 0. 如果 $E_w < V$, 则可以确认攻击者 B

盗取了 A 的模型, A 对模型 D'_q 具有所有权.

4 实验及结果分析

4.1 实验设置

通过实验对本文方案进行全面评估. 在评估有效性的同时, 对模型在原始任务上的准确性进行了评估, 并用保真度作为评测指标; 针对鲁棒性, 使用 4 种常见的水印去除攻击; 在对比实验方面, 将本文方案与 4 类方案^[7,19,22-23]进行比较; 在消融实验中, 针对权重对抗训练对模型水印鲁棒性的影响进行对照评估; 最后对触发集的隐秘性和扰动因子进行实验. 本文中, 2 种触发集图像均设置为 300 幅. 实验在一台配置 AMD R9-7945HX, 16 GB RAM 和一块 Nvidia RTX 4060 GPU 的机器上进行. 实验结果表明, 本文方案在各类模型上都表现出 100% 的水印提取率, 在鲁棒性方面显著优于现有模型水印方案.

4.2 水印评估指标

本文采用的 DNN 模型水印方案的评估指标及具体衡量方法如下.

(1) 有效性. 即模型水印提取率. 在模型中嵌入水印后, 对模型输入触发集, 通过计算式(9)得到水印提取率, 其值越高, 则水印精度越高, 有效性越好.

(2) 保真度. 嵌入水印后, 模型的原始任务一般有所降低, 通过计算模型在嵌入水印后与未嵌入时对原始任务的分类精度比值得到保真度.

(3) 鲁棒性. 水印信息在面对各种针对水印的攻击时, 依然可以满足验证模型所有权所属.

(4) 隐秘性. 提取水印时, 若触发集被攻击者检测为可疑图像, 则攻击者可能通过更改盗版模型的输出值干扰水印的正常提取, 因此有必要评估触发集的隐秘性.

4.3 有效性和保真度

表 1 所示为干净模型及其对应训练数据集的原始任务分类精度, 以及干净模型对特征结合的 2 类触发集的水印提取率. 可以看出, 干净模型的水印提取率最高只有 13%, 远低于阈值 50%. 这是由于触发集特殊的判别模式和本文方案设置的较大触发样本个数, 因此偶然被触发的水印图像占总体个数不具优势.

表 1 干净模型和原始任务分类精度

数据集	类别/个	干净模型	分类精度/%	特征混合/%	特征迁移/%
MNIST ^[31]	10	LeNet ^[31]	99.03	13.00	10.67
CIFAR-10 ^[32]	10	ResNet-18 ^[33]	93.63	10.33	10.00
CIFAR-100 ^[32]	100	VGG16 ^[34]	70.51	6.00	2.00

表2所示为水印模型的有效性和保真度, 其中, MNIST_LeNet 表示使用 MNIST 数据集和 LeNet 框架训练后的水印模型, CIFAR-10_ResNet-18 和 CIFAR-100_VGG16 同理. 可以看出, 2 种触发集方法的水印有效性均可达到 100%, 能够充分验证模

型所有权; 模型在嵌入水印后原始任务精度略有下降, 以表 1 的原始任务分类精度作为基准, 可知下降幅度在 1.5% 以内. 据此, 计算出的保真度均可保持在 98% 以上, 这表明水印模型具备良好的可用性, 即嵌入水印后模型依然可以被正常使用.

表 2 有效性和保真度 %

触发集	MNIST_LeNet			CIFAR-10_ResNet-18			CIFAR-100_VGG16		
	有效性	原始任务	保真度	有效性	原始任务	保真度	有效性	原始任务	保真度
特征混合	100	98.38	99.34	100	92.62	98.92	100	70.37	99.80
特征迁移	100	98.16	99.12	100	92.26	98.54	100	70.35	99.80

4.4 鲁棒性

由于攻击者会通过水印攻击方法阻碍所有权验证, 因此评估本文方案面对以下攻击后的鲁棒性.

4.4.1 微调攻击

由于微调攻击一般不会造成模型原始性能的显著降低, 因此攻击者常会利用此方法在保留模型可用性的条件下去除水印. 本文实验中, 选择 5% 的原始训练数据作为微调数据集, 迭代轮次设置为 100 个 epoch, 每 10 个 epoch 记录 1 次数据.

图 4 和图 5 为特征混合与特征迁移水印的微调

结果. 可以看出, 水印提取率精度均能达到 100%, 这表明本文方案能有效地抵抗微调攻击. 同时, 水印有效性始终维持不变, 没有因为微调攻击产生水印提取率精度的下降, 但是原始任务精度产生了微小起伏. 其中, 图 4c 在 CIFAR-100 上的原始任务效果, 在第 30 轮迭代和第 90 轮迭代后有所上升, 逼近甚至超越原有分类精度, 这是因为模型在微调过程中学习到训练集的新特征, 从而提高了原始分类精度.




图 4 微调攻击下特征混合水印精度




图 5 微调攻击下特征迁移水印精度

4.4.2 迁移学习攻击

攻击者一般希望在保留模型的原始性能的前提下去除水印,但是有时攻击者宁愿牺牲模型的可用性也要消除水印,往往通过迁移学习实现.使用强相关性或弱相关性的全新训练数据集对窃取模型进行迁移学习训练,使得水印信息被模型遗忘.实验的目标模型将使用已完成 CIFAR-10 数据集训练的 ResNet-18 模型,在嵌入水印后,分别用 CIFAR-100 和 MNIST 数据集进行 50 轮迁移学习训练,实验结果如表 3 所示.可以看出,水印提取率均大于 70%,可以有效地抵抗该攻击;使用 MNIST 的迁移学习对模型原始任务的损害更强,水印信息的提取率则降低了近 30%;而在 CIFAR-100 上的迁移学习对模型与水印的影响较弱.以上现象是因为弱相关性数据与原始数据关联性差,模型在学习时会改变大量的权重参数,导致降低已有的分类效果.


表 3 迁移学习攻击

数据集	触发集	原始任务	水印精度/%	
			攻击前	攻击后
CIFAR-100	特征混合	83.31	100	82.00
	特征迁移	83.06	100	80.33
MNIST	特征混合	39.22	100	71.33
	特征迁移	37.67	100	71.33


4.4.3 权重剪枝攻击

DNN 模型具有大量参数,其权重参数的冗余性特征使得模型在剪枝后删去部分权重后依然可以保持原有的分类精度,是高效的水印攻击手段.据此,攻击者可以通过权重剪枝方法删去记忆水印信息的参数,实现水印去除.


本文进行了剪枝率从 0 到 90% 的剪枝实验,图 6 和图 7 所示为特征混合水印和特征迁移水印的剪枝攻击结果.可以看出:(1) 在剪枝率未达到 70% 时,所有模型上的水印提取率均能维持在 100%;超过 70% 后,大部分模型水印效果开始下降;在剪枝率为 90% 的极端条件下,除了嵌入特征迁移水印的 CIFAR-100_VGG16 模型的水印提取率降至 50% 以下,其他模型水印提取率均高于支持所有权验证的阈值.表明水印对权重剪枝具有良好抵抗能力.(2) 2 种方法的 MNIST_LeNet 模型原始任务分类精度下降幅值较小,这是由于其分类任务较为简单,需要使用的神经元和参数较少,模型存在许多不重要的参数,因此,即使受到剪枝攻击,重要神经元被削减的概率较低;随着剪枝率的增加,原始任务精度和水印提取率最终都会被迫降低,但是原始任务的下降更为明显和剧烈,这是因为与水印任务相比,模型需要分配更多的参数用于学习原始任务.



a. MNIST_LeNet




b. CIFAR-10_ResNet-18




c. CIFAR-100_VGG16


图 6 剪枝攻击下的特征混合水印精度



a. MNIST_LeNet



b. CIFAR-10_ResNet-18



c. CIFAR-100_VGG16

图 7 剪枝攻击下的特征迁移水印精度

4.4.4 覆写攻击

攻击者可以通过在水印模型中插入新水印以

破坏旧有水印的验证效果. 为了评估对覆写攻击的鲁棒性, 本文利用已提出的特征结合方法构造新水印嵌入到水印模型. 实验中, 设置新水印的触发集 50 幅, 由特征混合和特征迁移方法共同生成, 二者各占一半; 将新水印触发集和部分原始训练数据投入到模型训练中以嵌入新水印. 新水印的标签值设置如表 4 所示. 可以看出, 特征混合或特

征迁移的原水印都不会在嵌入新水印时降低有效性, 本文方案对覆写攻击具有高度鲁棒性, 这是因为覆写过程与微调较为相似, 主要的区别是覆写比微调多了少量的新触发集图像. 由于嵌入训练所使用的训练数据量较大, 新触发集不占优势, 因此水印模型被更改的参数极少, 原水印的有效性能够保持不变.

表 4 覆写攻击下原水印有效性

水印模型	新水印标签	新水印/%	原水印-混合/%	原水印-迁移/%
MNIST_LeNet	5	100	100	100
CIFAR-10_ResNet18	6	100	100	100
CIFAR-100_VGG16	15	100	100	100

4.5 对比实验

将本文方案与已有的水印方案^[7,19,22-23]进行有效性、保真度和鲁棒性的对比实验. 目标模型为使用 CIFAR-10 作为原始任务的 ResNet-18 模型, 微调攻击轮次设置为 100 个 epoch, 迁移学习攻击设置为使用 CIFAR-100 进行迁移训练, 剪枝攻击的剪枝率设置为 80%, 覆写攻击的设置与前文一致, 实验结果如表 5 所示. 可以看出, 本文的 2 种方案在鲁棒性方面显著优于其他方案, 只有在保真度

方面的效果略低于文献[23]方案, 这是由于文献[23]方案专门为提高保真度而设计了新的损失函数. 但是文献[23]方案在抵抗各水印攻击的鲁棒性上效果则较差. 同时, 结果显示特征混合水印的保真度和鲁棒性都优于特征迁移水印, 这是由于特征混合触发集图像是由 2 个图像拼接而成, 具有明显的割裂感, 更加易于模型学习, 因此所需的记忆参数较少, 所以保真度较高且水印信息更为鲁棒.

表 5 不同方案下水印性能对比 %

方案	保真度	有效性	微调后精度	迁移学习后精度	剪枝后精度	覆写后精度
文献[7]	98.20	100	83.33	70.00	75.00	78.33
文献[19]	97.93	100	80.33	42.00	73.00	74.00
文献[22]	96.76	100	88.00	61.67	60.33	81.00
文献[23]	99.53	100	64.33	8.33	12.00	42.33
本文(混合)	98.92	100	100.00	82.00	94.67	100.00
本文(迁移)	98.54	100	100.00	80.33	94.00	100.00

注. 粗体表示最优值.

4.6 消融实验

为了验证权重对抗训练(简称为强化策略)对水印鲁棒性的强化作用, 对使用和未使用强化策略的模型水印进行消融实验.

图 8 为强化策略对水印抗微调攻击能力的影

响. 可以看出, 在 100 轮微调攻击迭代后, 本文的 2 种水印使用强化后能做到完全的水印提取; 未使用强化策略时, 2 种水印在 3 类模型上的提取率则较低. 说明添加权重扰动的对抗训练可以有效第强化水印抵抗微调攻击的能力.




图 8 有/无强化策略条件下的抗微调性能对比

图 9 和图 10 为有/无强化策略时, 水印对剪枝攻击的鲁棒性效果. 可以看出, 使用强化方法后, 水印提取率精度显著提高. 其中, 当剪枝率小于 60% 时, 有/无强化策略下模型水印精度都不会产生显著降低. 但是在模型的剪枝率设置为大于 60% 后, 2 种水印在有/无强化策略下的提取率差距则显著增加, 这是因为在嵌入水印时, 强化策略可以模拟出模型权重参数被攻击者修改的情况, 从而强化模型水印鲁棒性, 使得水印在模型权重

改变时仍然有较高的提取率.

4.7 触发集隐秘性

为了设置攻击者检测触发集的场景, 本文分别选取 2 类触发集各 2 500 幅图像(标签为可疑图像)和 2 500 幅来自 CIFAR-10 数据集的图像(标签为正常图像)作为训练集, 并使用 ResNet-18 训练了一个能够分类可疑图像和正常图像的分类器 C. 实验的目标是测试训练后的分类器 C 能否准确地分类触发集为可疑图像.




图 9 特征混合水印在有/无强化策略下抗剪枝性能对比




图 10 特征迁移水印在有/无强化策略下抗剪枝性能对比

实验结果如表 6 所示, 其中, 可疑图像率表示分类模型判定为可疑图像的触发集占该类触发集总数的比例; 注入噪声和加入内容是文献[7]设计的 2 种触发集模式, 二者分别通过对图像添加噪

声和在图像上添加有意义的像素标记(如一小块纯白像素)的方式构造触发图像. 可以看出, 文献[7]的 2 种触发集模式的可疑图像检测率都超过 98%, 而本文的 2 种触发集模式的检测率均低于文献[7],

更不容易被审查. 其中, 特征迁移方案的检测率只有 19.96%, 意味着攻击者无法通过可疑图像检测来干扰水印提取. 实验结果表明, 本文的触发集模式隐秘性更好, 这是因为特征迁移图像没有明显的模式, 其与正常图像相似度极高, 所以极难辨别; 特征混合图像因为存在 2 个图像合并的割裂痕迹, 而这是较为明显的模式, 因此分类器 C 易于辨认, 但是检测率仍低于对比方案.

表 6 不同方案下的触发集隐秘性对比

触发集设计	可疑图像/幅	可疑图像率/%
注入噪声 ^[7]	2500	100.00
加入内容 ^[7]	2467	98.68
特征混合	2377	95.08
特征迁移	499	19.96

4.8 扰动因子分析

式(5)中的 α 是可调节扰动的超参数, 本文对 α 取不同值时的水印对模型原始任务性能的影响及水印精度的高低进行实验. 首先选取特征混合触发集作为黑盒水印样本, 并挑选 CIFAR-10_ResNet-18 作为水印模型, 其未嵌水印时的原始任务精度为 93.63%; 然后分别取 α 为 0.01, 0.1, 1, 3, 6 和 9 时, 训练水印模型. 实验结果如表 7 所示.

表 7 不同扰动因子对模型和水印的影响 %

α	原始任务	水印精度
0.01	91.67	100.00
0.1	92.22	100.00
1	92.62	100.00
3	90.45	93.33
6	86.36	91.00
9	86.14	60.67

结果表明, 当 $\alpha=1$ 时效果最好, 原始任务精度为 92.62%且水印精度为 100%. 同时可以看出, 随着扰动的增加, 模型的原始分类任务精度下降, 这是因为扰动强度的增加使得反向传播时权重更新过于剧烈; 当 α 取 0.01~1 时, 水印提取率可以达到 100%的精度效果, 但是当扰动从 3 增加至 9 时, 水印提取率会大幅降低. 实验结果表明, 模型水印会在一定程度上造成模型原始分类精度的降低, 但是只要选取恰当的扰动, 就能在模型性能几乎维持不变的基础上实现水印嵌入.

5 结 语

本文提出一种保护 DNN 模型的黑盒后门水

印方案. 首先从特征结合的角度出发设计了降低水印学习成本的触发集, 然后在水印嵌入阶段添加扰动进行权重对抗训练, 最后使用黑盒验证方式实现所有权证明. 实验结果表明, 本文方案在各种图像分类任务上均具有良好的有效性、保真度及鲁棒性, 能够抵御微调攻击、迁移学习攻击、权重剪枝攻击及覆写攻击, 实验结果显著优于现有的其他水印方案.

模型提取攻击是一种最近出现的新颖攻击方式, 该攻击通过查询模型来拷贝其功能从而间接盗取模型. 未来将针对这种新颖的攻击, 利用模型的固有特性实现对攻击者的代理模型植入水印, 并将其扩展应用至大模型上.

参考文献(References):

- [1] Ouyang L, Wu J, Jiang X, et al. Training language models to follow instructions with human feedback[OL]. [2023-12-18]. <https://arxiv.org/abs/2203.02155>
- [2] Yin Hao, Lin Chuang, Qiu Feng, et al. A survey of digital watermarking[J]. Journal of Computer Research and Development, 2005, 42(7): 1093-1099(in Chinese)
(尹浩, 林闯, 邱锋, 等. 数字水印技术综述[J]. 计算机研究与发展, 2005, 42(7): 1093-1099)
- [3] Gu Yuxin, Ma Xiaohu. Digital watermarking algorithm using sparse transform and Laplace pyramid[J]. Journal of Computer-Aided Design & Computer Graphics, 2018, 30(5): 901-910(in Chinese)
(顾宇鑫, 马小虎. 采用稀疏变换和拉普拉斯金字塔的数字水印算法[J]. 计算机辅助设计与图形学学报, 2018, 30(5): 901-910)
- [4] Fang H, Jia Z Y, Ma Z H, et al. PIMoG: an effective screen-shooting noise-layer simulation for deep-learning-based watermarking network[C] //Proceedings of the 30th ACM International Conference on Multimedia. New York: ACM Press, 2022: 2267-2275
- [5] Wu Hanzhou, Zhang Jie, Li Yue, et al. Overview of artificial intelligence model watermarking[J]. Journal of Image and Graphics, 2023, 28(6): 1792-1810(in Chinese)
(吴汉舟, 张杰, 李越, 等. 人工智能模型水印研究进展[J]. 中国图象图形学报, 2023, 28(6): 1792-1810)
- [6] Uchida Y, Nagai Y, Sakazawa S, et al. Embedding watermarks into deep neural networks[C] //Proceedings of the ACM on International Conference on Multimedia Retrieval. New York: ACM Press, 2017: 269-277
- [7] Zhang J L, Gu Z S, Jang J, et al. Protecting intellectual property of deep neural networks with watermarking[C] //Proceedings of the Asia Conference on Computer and Communications Security. New York: ACM Press, 2018: 159-172
- [8] Le Merrer E, Pérez P, Trédan G. Adversarial frontier stitching for remote neural network watermarking[J]. Neural Computing and Applications, 2020, 32(13): 9233-9244
- [9] Wang T H, Kerschbaum F. Attacks on digital watermarks for deep neural networks[C] //Proceedings of the IEEE International Conference on Acoustics, Speech and Signal Processing. Los Alamitos: IEEE Computer Society Press, 2019: 2622-2626
- [10] Chen H L, Rouhani B D, Fu C, et al. DeepMarks: a secure fingerprinting framework for digital rights management of

- deep learning models[C] //Proceedings of the International Conference on Multimedia Retrieval. New York: ACM Press, 2019: 105-113
- [11] Liu H W, Weng Z Y, Zhu Y S. Watermarking deep neural networks with greedy residuals[C] //Proceedings of the 38th International Conference on Machine Learning. New York: PMLR, 2021: 6978-6988
- [12] Rouhani B D, Chen H L, Koushanfar F. DeepSigns: an end-to-end watermarking framework for ownership protection of deep neural networks[C] //Proceedings of the 24th International Conference on Architectural Support for Programming Languages and Operating Systems. New York: ACM Press, 2019: 485-497
- [13] Wang J F, Wu H Z, Zhang X P, *et al.* Watermarking in deep neural networks via error back-propagation[J]. *Electronic Imaging*, 2020, 32(4): 1-9
- [14] Fan L X, Ng K W, Chan C S. Rethinking deep neural network ownership verification: embedding passports to defeat ambiguity attacks[C] //Proceedings of the 33rd International Conference on Neural Information Processing Systems. Massachusetts: New York: Curran Associates Inc., 2019: 4716-4725
- [15] Fan L X, Ng K W, Chan C S, *et al.* DeepIPR: deep neural network ownership verification with passports[J]. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 2022, 44(10): 6122-6139
- [16] Zhang J, Chen D D, Liao J, *et al.* Passport-aware normalization for deep model protection[C] //Proceedings of the 34th International Conference on Neural Information Processing Systems. New York: Curran Associates Inc., 2020: Article No.1896
- [17] Lou X X, Guo S W, Li J W, *et al.* Ownership verification of DNN architectures via hardware cache side channels[J]. *IEEE Transactions on Circuits and Systems for Video Technology*, 2022, 32(11): 8078-8093
- [18] Li Y M, Jiang Y, Li Z F, *et al.* Backdoor learning: a survey[OL]. [2023-12-18]. <https://arxiv.org/abs/2007.08745>
- [19] Adi Y, Baum C, Cissé M, *et al.* Turning your weakness into a strength: watermarking deep neural networks by backdoor-ing[C] //Proceedings of the 27th USENIX Security Symposium. Berkeley: USENIX Association Press, 2018: 1615-1631
- [20] Jia H R, Choquette-Choo C A, Chandrasekaran V. Entangled watermarks as a defense against model extraction[C] //Proceedings of the 30th USENIX Security Symposium. Berkeley: USENIX Association Press, 2021: 1937-1954
- [21] Li M, Zhong Q, Zhang L Y, *et al.* Protecting the intellectual property of deep neural networks with watermarking: the frequency domain approach[C] //Proceedings of the 19th IEEE International Conference on Trust, Security and Privacy in Computing and Communications. Los Alamitos: IEEE Computer Society Press, 2020: 402-409
- [22] Xue M F, Sun S C, Zhang Y S, *et al.* Active intellectual property protection for deep neural networks through stealthy backdoor and users' identities authentication[J]. *Applied Intelligence*, 2022, 52(14): 16497-16511
- [23] Hua G, Teoh A B J. Deep fidelity in DNN watermarking: a study of backdoor watermarking for classification models[J]. *Pattern Recognition*, 2023, 144: Article No.109844
- [24] Goodfellow I J, Shlens J, Szegedy C. Explaining and harnessing adversarial examples[OL]. [2023-12-18]. <http://arxiv.org/abs/1412.6572>
- [25] Chen H L, Rouhani B D, Koushanfar F. BlackMarks: blackbox multibit watermarking for deep neural networks[OL]. [2023-12-18]. <https://arxiv.org/abs/1904.00344>
- [26] Yang P, Lao Y J, Li P. Robust watermarking for deep neural networks via Bi-level optimization[C] //Proceedings of the IEEE/CVF International Conference on Computer Vision. Los Alamitos: IEEE Computer Society Press, 2021: 14821-14830
- [27] Chen J L, Wang J Y, Peng T L, *et al.* Copy, right? A testing framework for copyright protection of deep learning models[C] //Proceedings of the IEEE Symposium on Security and Privacy. Los Alamitos: IEEE Computer Society Press, 2022: 824-841
- [28] Szyller S, Atli B G, Marchal S, *et al.* DAWN: dynamic adversarial watermarking of neural networks[C] //Proceedings of the 29th ACM International Conference on Multimedia. New York: ACM Press, 2021: 4417-4425
- [29] Charette L, Chu L Y, Chen Y Z, *et al.* Cosine model watermarking against ensemble distillation[C] //Proceedings of the 36th AAAI Conference on Artificial Intelligence. Palo Alto: AAAI Press, 2022: 9512-9520
- [30] Zhu J Y, Park T, Isola P, *et al.* Unpaired image-to-image translation using cycle-consistent adversarial networks[C] //Proceedings of the IEEE International Conference on Computer Vision. Los Alamitos: IEEE Computer Society Press, 2017: 2242-2251
- [31] LeCun Y, Bottou L, Bengio Y, *et al.* Gradient-based learning applied to document recognition[J]. *Proceedings of the IEEE*, 1998, 86(11): 2278-2324
- [32] Krizhevsky A, Hinton G. Learning multiple layers of features from tiny images[R]. Toronto: University of Toronto, 2009
- [33] He K M, Zhang X Y, Ren S Q, *et al.* Deep residual learning for image recognition[C] //Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. Los Alamitos: IEEE Computer Society Press, 2016: 770-778
- [34] Simonyan K, Zisserman A. Very deep convolutional networks for large-scale image recognition[OL]. [2023-12-18]. <https://arxiv.org/abs/1409.1556>